

Thực hành Nguyên Lý Máy Học

Buổi 3: Bayes thơ ngây

Mục tiêu:

- Củng cố lý thuyết và cài đặt giải thuật Bayes thơ ngây
- Sử dụng hàm có sẵn của Python để cài đặt giải thuật Bayes thơ ngây.
- Kiểm thử và đánh giá

A. HƯỚNG DẪN THỰC HÀNH

1. Hiểu nguyên lý hoạt động của giải thuật xây dựng mô hình Bayes ngây thơ

- Đọc dữ liệu từ file: “play_tennis.csv”

```
import pandas as pd
dt = pd.read_csv("play_tennis.csv")
dt|
>>> dt
      Outlook  Temp  Humidity  Windy  Play
0     Sunny   Hot    High   False   No
1     Sunny   Hot    High    True   No
2  Overcast   Hot    High   False   Yes
3     Rainy  Mild    High   False   Yes
4     Rainy  Cool   Normal   False   Yes
5     Rainy  Cool   Normal    True   No
6  Overcast  Cool   Normal    True   Yes
7     Sunny  Mild    High   False   No
8     Sunny  Cool   Normal   False   Yes
9     Rainy  Mild   Normal   False   Yes
10    Sunny  Mild   Normal    True   Yes
11  Overcast  Mild    High    True   Yes
12  Overcast   Hot   Normal   False   Yes
13    Rainy  Mild    High    True   No
```

- Tính xác suất có điều kiện $P(\text{Outlook}/\text{Play} = \text{"yes"})$. Bảng phân phối xác suất có dạng

Outlook/Play = Yes	Sunny	overcast	rainny
P			

Gợi ý :

- Tìm giá trị Outlook của các phần tử có Play = “Yes”

dt.Outlook[dt.Play=="Yes"]

Hoặc

PlayYes = dt[dt.Play=="Yes"]

PlayYes.Outlook

- Thống kê tần số xuất hiện của các giá trị, chuẩn hoá cho tổng bằng 1 => bảng phân phối xác suất.

dtO = dt.Outlook[dt.Play=="Yes"]

```
P1_1 = dtO.value_counts() # số lần xuất hiện của mỗi giá trị của thuộc tính Outlook
P1_1 = P1_1/dtO.count()
```

P1.1 sẽ lưu giữ bảng phân phối xác suất có điều kiện của Outlook khi biết giá trị Play = yes

```
>>> P1_1
Overcast    0.444444
Rainy       0.333333
Sunny       0.222222
Name: Outlook, dtype: float64
```

c. Tương tự như trên tính, xác suất $P(\text{Outlook}/\text{Play}=\text{"no"})$ lưu vào biến P1.2

d. Lặp lại các bước a,b,c cho cột Temperature gán vào các biến: P2.1, P2.2

```
dtTy = dt.Temp[dt.Play=="Yes"]
P2_1 = dtTy.value_counts()/dtTy.count()
dtTn = dt.Temp[dt.Play=="No"]
P2_2 = dtTn.value_counts()/dtTn.count()
P2_1
P2_2
```

e. Lặp lại các bước a,b,c cho cột Humidity gán vào các biến: P3.1, P3.2

f. Lặp lại các bước a,b,c cho cột Windy gán vào các biến: P4.1, P4.2

g. Tính xác suất $P(\text{Play})$, lưu vào biến P

```
Play = dt.Play.value_counts()/dt.Play.count()
Play
```

Bước 2: Dự báo nhãn cho dữ liệu

Sử dụng các bảng xác suất trên dự báo nhãn cho dữ liệu

X = ("rainy", "cool", "high", "false")

```
P_yes = P1_1[1]*P2_1[1]*P3_1[1]*P4_1[0]*Play[0]
P_no = P1_2[1]*P2_2[1]*P3_2[1]*P4_2[0]*Play[1]

Hoac

P_yes = P1_1.Rainy*P2_1.Cool*P3_1.High*P4_1.F*Play.Yes
P_no = P1_2.Rainy*P2_2.Cool*P3_2.High*P4_2.F*Play.No

P_yes
P_no
PY = P_yes/(P_no+P_yes)
PN = P_no/(P_no+P_yes)
PY
PN
```

2. Sử dụng thư viện scikit-learn của Python

a. Dữ liệu Iris

Xét bài toán phân loại hoa IRIS dựa trên thông tin về kích thước của cánh hoa và đài hoa. Tập dữ liệu này có 150 phần tử, mỗi loại hoa có 50 phần tử.



Tập dữ liệu này có thể download từ trang UCI (<https://archive.ics.uci.edu/ml/datasets/iris>) rồi đọc dữ liệu bằng lệnh `read_csv` của thư viện **Pandas** như đã hướng dẫn ở buổi thực hành 2 hoặc có thể nạp dữ liệu có sẵn bởi thư viện **Sklearn**.

Trực tiếp bởi thư viện

```
from sklearn import datasets
iris = datasets.load_iris()
X = iris.data
y = iris.target
```

- b. Sử dụng sklearn để xây dựng mô hình bayes thơ ngây
- Dữ liệu kiểu số => giả sử các thuộc tính có phân phối *Gaussian*
Hàm mật độ xác suất được tính bởi công thức

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Trong đó:

$$\mu = \frac{1}{n} \sum_{i=1}^n x_i \quad \sigma^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \mu)^2$$

- Sklearn cung cấp sẵn hàm để tính mật độ xác suất theo phân phối Gaussian cho dữ liệu kiểu liên tục cũng như Multinomial (phân loại văn bản), BernoulliNB,...

```
from sklearn.naive_bayes import GaussianNB
from sklearn.naive_bayes import MultinomialNB
```

- Sử dụng hàm `train_test_split()` để phân chia dữ liệu theo nghi thức hold-out, xây dựng mô hình theo phân phối Gaussian và so sánh kết quả dự đoán so với kết quả thực tế.

```
# Phân chia dữ liệu thành tập test và train
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=0)
#Xây dựng mô hình dựa trên phân phối xác suất tuân theo Gaussian
model = GaussianNB()
model.fit(X_train, y_train)
print(model)
# dự đoán
thucte = y_test
dubao = model.predict(X_test)
thucte
dubao
```

- Sử dụng hàm `confusion_matrix()` để đánh giá giải thuật

```
from sklearn.metrics import confusion_matrix
cnf_matrix_gnb = confusion_matrix(thucte, dubao)
print(cnf_matrix_gnb)
[[16  0  0]
 [ 0 18  0]
 [ 0  0 11]]
```

- c. Sử dụng nghi thức k-fold để phân chia tập dữ liệu “iris” với k=15 với hàm Kfold

```
class sklearn.model_selection
    KFold(n_splits=3, shuffle=False, random_state=None)
```

- **`n_splits`** : int, default=3
Number of folds. Must be at least 2.
- **`shuffle`** : boolean, optional
Whether to shuffle the data before splitting into batches.
- **`random_state`** : int, RandomState instance or None, optional, default=None
If int, `random_state` is the seed used by the random number generator; If RandomState instance, `random_state` is the random number generator; If None, the random number generator is the RandomState instance used by `np.random`. Used when `shuffle == True`.

```
from sklearn.model_selection import KFold
kf= KFold(n_splits=15) # chia tập dữ liệu thành 15 phần
```

```
for train_index, test_index in kf.split(X):
    # print("TRAIN:", train_index, "TEST:", test_index)
    X_train, X_test = X.iloc[train_index,], X.iloc[test_index,]
    y_train, y_test = y.iloc[train_index], y.iloc[test_index]
#     print ("X_test", X_test) # In thuộc tính của dữ liệu kiểm tra
    print("=====")
```

BÀI TẬP THỰC HÀNH
BUỔI 3 – GIẢI THUẬT BAYES THƠ NGÂY
Deadline 20/4/21

1. Download tập dữ liệu “**winequality-white**” và gán vào biến **wineWhite**. Dữ liệu có bao nhiêu thuộc tính? Cột nào là cột nhãn? Giá trị của các nhãn (ghi lại kết quả và code vào file nộp bài)
2. Với tập dữ liệu **wineWhite** sử dụng nghi thức K-Fold để phân chia tập dữ liệu huấn luyện với $K=100$, sử dụng tham số “Shuffle” để xáo trộn tập dữ liệu trước khi phân chia. Xác định số lượng phần tử có trong tập test và tập huấn luyện nếu sử dụng nghi thức đánh giá này.
3. Sử dụng giải thuật **Bayes thơ ngây** (hàm sklearn) để dự đoán nhãn cho tập kiểm tra theo nghi thức đánh giá của câu 2 với phân phối xác suất Gaussian
4. Đánh giá độ chính xác cho từng phân lớp dựa vào giá trị dự đoán của câu 3 cho mỗi lần lặp. Chép lại kết quả độ chính xác cho từng phân lớp của lần lặp cuối nộp lại (có thể đưa vào comment trong file code).
5. Tính độ chính xác tổng thể cho mỗi lần lặp và độ chính xác tổng thể của trung bình **70 lần lặp**.
6. Sử dụng giải thuật Cây quyết định (Decision Tree) ở buổi thực hành số 2 để so sánh hiệu quả phân lớp của giải thuật Bayes thơ ngây và cây quyết định với nghi thức đánh giá **hold-out**